



Universidade Federal do ABC
Centro de Matemática, Computação e Cognição
Bacharelado em Ciência da Computação

Plano de trabalho PGC

PhonAPI: uma camada de abstração para integração de modelos de transcrição fonética automática em aplicações de fonoaudiologia

Aluno(a): Guilherme Meira Rebello
Orientador: Prof. Diogo S. Martins

Introdução

Transtornos dos sons da fala (do inglês *Speech Sound Disorders*, SSDs) afetam até 24,6% das crianças (Niegia *et al.*, *apud* Dadgar *et al.*, 2025), porém apenas uma parcela reduzida desses pacientes recebe tratamento adequado e consistente. A terapia fonoaudiológica (do inglês *Speech and Language Therapy*, SLT) é amplamente reconhecida como intervenção eficaz para o manejo desses distúrbios (Dadgar *et al.*, 2025), e o diagnóstico precoce contribui significativamente para a qualidade do tratamento e as taxas de sucesso terapêutico. Entretanto, a elaboração de planos terapêuticos personalizados demanda tempo e esforço significativos dos fonoaudiólogos, tornando o processo intensivo em recursos (Dadgar *et al.*, 2025). Tecnologias digitais têm potencial para reduzir a escassez de profissionais e diminuir custos e tempo associados à terapia tradicional.

Nos últimos anos, tecnologias baseadas em inteligência artificial têm sido desenvolvidas para apoiar esse cenário clínico. Ferramentas computacionais demonstraram eficácia no suporte diagnóstico, oferecendo planos de terapia personalizados e *feedback* em tempo real, além de se mostrarem mais engajantes para crianças do que a terapia tradicional (Dadgar *et al.*, 2025). Modelos de reconhecimento automático de fala (do inglês *Automatic Speech Recognition*, ASR) e de transcrição fonética automática (do inglês *Automatic Phonetic Transcription*, APT) têm sido propostos para automatizar a transcrição fonética e a detecção de distúrbios. Li *et al.* (2025) propuseram um modelo baseado em wav2vec 2.0 para automatizar a transcrição fonética e o alinhamento forçado de fala infantil com distúrbios. Kim *et al.* (2025) e Lin, Tseng e Jang (2024) demonstraram a aplicabilidade de sistemas ASR para avaliação da fala infantil. Rocha (2024) desenvolveu um *dataset* e um modelo APT para português brasileiro, também utilizando wav2vec 2.0, e compartilhou o modelo publicamente no repositório Hugging Face. Diversos aplicativos móveis também já foram desenvolvidos nessa direção, como o Vox4Health para detecção de distúrbios vocais (Cesari *et al.*, 2018), o OLA App para terapia vocal (Schröder *et al.*, 2024) e aplicações iOS para adesão à terapia (Van Leer; Lewis; Porcaro, 2021).

Apesar desse volume crescente de pesquisas, existe uma lacuna importante entre a produção acadêmica de modelos de reconhecimento de áudio e a sua implementação prática em sistemas utilizáveis por terapeutas e pacientes. A maioria dos estudos foca no desenvolvimento de modelos de *machine learning* para detecção de distúrbios, conforme identificado na revisão de escopo de Dadgar *et al.* (2025), que apontou a detecção como o foco primário da maioria dos artigos revisados. Poucos trabalhos, porém, oferecem uma solução de ponta a ponta que permita a integração desses modelos em aplicações reais. As soluções existentes tendem a ser fortemente acopladas: o modelo de IA e a aplicação formam uma unidade indivisível, dificultando a reutilização, substituição ou evolução independente dos componentes.

Essa distância entre o desenvolvimento de modelos e a sua operacionalização em aplicações é um problema reconhecido na engenharia de software. Pahl e Loipfinger (2018) identificaram que, embora *machine learning* esteja se tornando uma ferramenta

universal de resolução de problemas, implementá-lo em aplicações é difícil, consome tempo e requer conhecimento especializado. Panchal *et al.* (2023) observaram que as competências necessárias para entender o problema de negócio, desenvolver modelos e desenvolver aplicações são distintas, o que dificulta a produtividade rápida dos modelos. Dovbysh e Aliksieiev (2020) apontam que o principal problema de integrar soluções de reconhecimento de fala de terceiros em software próprio é que quaisquer melhorias no componente de terceiros estão fora do controle do desenvolvedor.

As revisões existentes sobre SLT pediátrica reforçam essa lacuna. Dadgar *et al.* (2025) observaram que os trabalhos prévios focam predominantemente em aplicações e jogos, enfatizando *design* de jogos e análise de sistemas em alto nível. Atwell *et al.* (*apud* Dadgar *et al.*, 2025) listam brevemente os algoritmos de ML utilizados sem fornecer análise detalhada sobre o processo de desenvolvimento, avaliação e resultados. Saeedi *et al.* (*apud* Dadgar *et al.*, 2025) focam primariamente no *design* de jogos, não nos modelos de IA ou implementação. Moulaei *et al.* (*apud* Dadgar *et al.*, 2025) avaliam teleterapia de uma perspectiva de alto nível, sem aprofundar nas soluções dirigidas por IA, ou nos aspectos de desenvolvimento. Mannino *et al.* (2023) oferecem um guia para o desenvolvimento de aplicações médicas móveis, mas sem abordar a questão da integração modular de modelos de IA. Vaezipour *et al.* (2020) revisaram aplicativos móveis para SLT em adultos, avaliando conteúdo e qualidade, mas novamente sem foco na arquitetura de software que permita integração flexível de modelos.

Do lado da engenharia de software, existem abordagens para facilitar a integração e o implantação, ou *deployment*, de modelos de ML em aplicações, mas nenhuma direcionada especificamente ao domínio de SLT e transcrição fonética. Dentre as abordagens existentes, destacam-se as ferramentas envolvidas no processo de *model serving*, que consiste em implantar modelos de aprendizado de máquina em ambientes de produção, tornando-os acessíveis a outras aplicações via interfaces de programação. TensorFlow Serving, TorchServe, MLflow, MLServer e BentoML são exemplos de ferramentas dessa categoria que oferecem infraestrutura para servir modelos em produção. De Rosa *et al.* (2024) avaliaram o desempenho desses cinco

frameworks e demonstraram que *frameworks* específicos para *deep learning* apresentam latências significativamente menores que *frameworks* de propósito geral. Contudo, esses *frameworks* são genéricos e de baixo nível: oferecem a infraestrutura para servir qualquer modelo, mas não fornecem uma interface padronizada específica para o domínio de transcrição fonética. No campo de microserviços, Pahl e Loipfinger (2018) propuseram a encapsulação de algoritmos de ML como microserviços REST reutilizáveis com separação estrita entre algoritmo e configuração; Ribeiro *et al.* (2019) propuseram o MLMA, uma arquitetura genérica baseada em *design patterns* para transformar *pipelines* monolíticos de ML em microserviços; e Panchal *et al.* (2023) demonstraram como a plataforma Acumos pode transformar modelos heterogêneos em microserviços funcionais. Essas soluções, no entanto, não foram aplicadas ao domínio de transcrição fonética e não oferecem uma abstração no nível semântico do domínio. Alomairy *et al.* (2020) introduziram o AL4SAN, uma biblioteca leve para abstrair as APIs de diferentes *engines* computacionais, expondo APIs comuns no *frontend* e conectando-se a diferentes *backends* de forma transparente, com *overhead* inferior a 10%. Essa abordagem é conceitualmente análoga ao que este trabalho propõe para modelos de transcrição fonética: um *frontend* unificado que abstrai *backends* intercambiáveis. Singjai *et al.* (2022) apresentaram padrões para derivar APIs a partir de modelos de domínio, fornecendo diretrizes para projetar APIs que reflitam adequadamente o domínio da aplicação. Já os serviços comerciais de *speech-to-text* como Google Speech-to-Text, Azure Speech Services e AWS Transcribe oferecem APIs robustas, mas com limitações para o contexto de pesquisa em SLT: são voltados para transcrição ortográfica e não fonética (IPA), operam como caixas-pretas proprietárias, geram dependência de fornecedor e podem ter custos proibitivos para pesquisadores.

Assim, embora exista pesquisa significativa tanto no lado dos modelos de IA para fala quanto no lado da engenharia de software para *deployment* de modelos, falta uma ponte entre esses dois mundos. A ausência de uma camada de serviço genérica e desacoplada que permita integrar diferentes modelos de transcrição fonética automática (*speech-to-IPA*) em aplicações de apoio à fonoaudiologia, e potencialmente

a outros domínios, dificulta a transição de pesquisas acadêmicas para implementações práticas. Esse é o problema central investigado neste trabalho.

Justificativa

O problema é relevante tanto do ponto de vista clínico quanto do tecnológico. No plano clínico, a alta prevalência de distúrbios da fala em crianças, combinada com a escassez de profissionais e o custo da terapia personalizada, cria uma demanda por ferramentas tecnológicas acessíveis. No plano tecnológico, a pesquisa em modelos de reconhecimento de fala (incluindo modelos como wav2vec 2.0 para transcrição fonética em inglês e em português brasileiro) avança rapidamente, mas os artefatos produzidos ficam restritos ao contexto acadêmico por falta de uma camada de integração padronizada.

A abordagem proposta, uma API genérica e desacoplada para integração de modelos de transcrição fonética automática, diferencia-se das soluções existentes em cinco aspectos principais.

O primeiro é o desacoplamento entre modelo e aplicação. Soluções como o Vox4Health (Cesari *et al.*, 2018) e os sistemas revisados por Dadgar *et al.* (2025) integram modelo e aplicação de forma monolítica. A API proposta, por outro lado, permite que modelos sejam substituídos, atualizados ou combinados independentemente da aplicação consumidora. Essa separação segue o princípio documentado por Pahl e Loipfinger (2018) de separação estrita entre algoritmo e configuração, e é análoga à arquitetura de *frontend* unificado com *backends* intercambiáveis do AL4SAN (Alomairy *et al.*, 2020).

O segundo aspecto é o caráter agnóstico ao modelo. A API não se limita a um modelo específico de transcrição fonética, possibilitando o uso de diferentes algoritmos (modelos baseados em wav2vec 2.0, Whisper, ou outros *frameworks* de ASR/APT) conforme a necessidade do contexto, seja para português brasileiro, inglês, ou fala infantil com distúrbios. Diferentemente das APIs comerciais (Google Speech-to-Text,

Azure Speech Services, AWS Transcribe), a API proposta permite a integração de modelos desenvolvidos pela comunidade acadêmica, sem dependência de fornecedor e com foco em transcrição fonética (IPA), não apenas ortográfica.

O terceiro aspecto diz respeito à facilidade de transição entre academia e prática. Ao oferecer uma interface padronizada no nível semântico do domínio (por exemplo, enviar áudio e receber transcrição em IPA), pesquisadores que desenvolvem novos modelos de reconhecimento fonético podem torná-los disponíveis para aplicações reais sem precisar construir toda a infraestrutura de uma aplicação completa. Essa abordagem guarda semelhança com a proposta por Panchal *et al.* (2023) na plataforma Acumos, mas é especializada no domínio de transcrição fonética.

O quarto aspecto é a fundamentação em engenharia de software. A arquitetura da API utiliza conceitos como o padrão *Strategy* (para abstração dos modelos) e o padrão *Adapter* (para uniformização das interfaces de entrada e saída de modelos heterogêneos). O *design* dos *endpoints* segue os padrões de derivação de APIs a partir de modelos de domínio propostos por Singjai *et al.* (2022). A plataforma será implementada como uma API web REST, escolha justificada pela ampla adoção do protocolo HTTP, pela facilidade de integração com aplicações web e móveis, e pela compatibilidade com os *frameworks* de *model serving* existentes (De Rosa *et al.*, 2024).

Por fim, a proposta se diferencia dos *frameworks* existentes de *model serving*. Embora *frameworks* como TensorFlow Serving e TorchServe (De Rosa *et al.*, 2024) ofereçam infraestrutura para servir modelos, eles operam no nível genérico de inferência de qualquer modelo, sem oferecer abstração semântica para o domínio de transcrição fonética. Da mesma forma, arquiteturas de microserviços para ML como as propostas por Ribeiro *et al.* (2019) e Roh *et al.* (2023) focam na infraestrutura genérica de MLOps, sem adaptar a interface ao domínio de SLT. A API proposta neste trabalho atua em um nível acima: consome esses *frameworks* como infraestrutura e oferece uma interface de domínio específica para transcrição fonética.

Objetivos

- Investigar o estado da arte em modelos de transcrição fonética automática (*speech-to-IPA*) aplicados à fonoaudiologia, com foco em modelos para detecção de distúrbios da fala e em modelos para diferentes idiomas.
- Analisar as arquiteturas de software empregadas nas soluções existentes de SLT assistida por tecnologia e em *frameworks* de *model serving*, identificando padrões de acoplamento, integração e abstração.
- Projetar uma API genérica e desacoplada (*model-agnostic*) para integração de modelos de transcrição fonética automática em aplicações de apoio à fonoaudiologia, fundamentada em padrões de *design* de APIs e de software (Strategy, Adapter, Domain Model Facade).
- Prototipar a API proposta, implementando a integração com dois modelos de transcrição fonética automática de perfis distintos, por exemplo, um modelo voltado para português brasileiro e outro para uma língua estrangeira ou para contexto clínico de fala infantil, a fim de demonstrar o caráter agnóstico da API. Os modelos específicos serão selecionados na fase de implementação com base em critérios de disponibilidade pública e facilidade de integração.
- Avaliar a API proposta em dois eixos: (a) comparação arquitetural qualitativa entre a solução proposta e soluções existentes (tanto acadêmicas, conforme levantadas por Dadgar et al. (2025), quanto comerciais como Google Speech-to-Text e Azure Speech Services), analisando critérios como nível de acoplamento, possibilidade de substituição de modelos e extensibilidade, conforme abordagem empregada por De Rosa et al. (2024) na comparação de *frameworks* de *model serving*; e (b) validação técnica por meio de benchmark de latência, medindo o *overhead* introduzido pela camada de abstração em comparação com a invocação direta dos modelos.

Metodologia

Tarefa 1: Revisão bibliográfica

Pesquisar nas bases de dados PubMed, Scopus, ScienceDirect, ACM Digital Library e IEEE Xplore, complementando com Google Scholar. As buscas serão organizadas em dois eixos temáticos. O primeiro eixo, voltado a modelos de transcrição fonética e IA aplicada à fonoaudiologia, utilizará termos como *"automatic phonetic transcription"*, *"speech-to-IPA"*, *"speech sound disorder"*, *"automatic speech recognition"*, *"speech therapy"* e *"machine learning"*. O segundo eixo, voltado à engenharia de software e integração de modelos, utilizará termos como *"model serving"*, *"API design"*, *"microservices"*, *"machine learning deployment"* e *"software architecture"*. Os termos de cada eixo serão combinados com o operador OR internamente e AND entre eixos, quando pertinente. Serão selecionados artigos publicados entre 2018 e 2026. A análise dos trabalhos priorizará: modelos de IA utilizados e suas características (idioma, tipo de transcrição, disponibilidade pública), nível de acoplamento entre modelo e aplicação nas soluções existentes, presença ou ausência de camada de serviço ou abstração, e métricas de avaliação empregadas.

Tarefa 2: Levantamento de requisitos e análise de soluções existentes

A partir da revisão bibliográfica e da análise de APIs comerciais de speech-to-text (Google Speech-to-Text, Azure Speech Services, AWS Transcribe), identificar os requisitos funcionais e não-funcionais para uma API genérica de integração de modelos de transcrição fonética. Essa análise incluirá o levantamento das funcionalidades oferecidas por cada serviço, suas limitações para o contexto de pesquisa em SLT (por exemplo, ausência de transcrição em IPA, dependência de fornecedor, custos) e os padrões de interface adotados. Também serão analisados os frameworks de model serving (TensorFlow Serving, TorchServe, BentoML, entre outros) quanto às suas capacidades de abstração e extensibilidade, com base no trabalho de De Rosa et al. (2024).

Tarefa 3: Projeto da arquitetura

Definir a arquitetura da API, incluindo endpoints, formatos de entrada e saída, protocolos de comunicação e mecanismos de abstração de modelos. O projeto utilizará os padrões de design Strategy (para permitir a troca de modelos de forma transparente) e Adapter (para uniformizar as interfaces de modelos heterogêneos), além de seguir as diretrizes de derivação de APIs a partir de modelos de domínio propostas por Singjai et al. (2022). A documentação da arquitetura incluirá especificação OpenAPI e diagramas de componentes.

Tarefa 4: Prototipação

Implementar o protótipo da API como uma aplicação web REST. Integrar ao menos dois modelos de transcrição fonética automática de perfis distintos, por exemplo, o modelo de Rocha (2024) para português brasileiro e um modelo voltado a outro idioma ou a fala infantil com distúrbios, a fim de demonstrar o caráter agnóstico da API. A seleção final dos modelos será feita com base em critérios de disponibilidade pública (por exemplo, modelos hospedados no Hugging Face) e facilidade de integração via os adaptadores projetados na Tarefa 3.

Tarefa 5: Avaliação

A avaliação será conduzida em dois eixos. O primeiro eixo consiste em uma comparação arquitetural qualitativa entre a API proposta e soluções existentes (acadêmicas e comerciais), analisando critérios como nível de acoplamento, possibilidade de substituição de modelos, extensibilidade e adequação ao domínio de transcrição fonética. O segundo eixo consiste em uma validação técnica por meio de benchmark de latência, medindo o overhead introduzido pela camada de abstração da API em comparação com a invocação direta dos modelos integrados, seguindo abordagem análoga à empregada por De Rosa et al. (2024).

Tarefa 6: Escrita e defesa da monografia

Escrita dos capítulos da monografia (introdução, fundamentação teórica, trabalhos relacionados, proposta, implementação, avaliação, conclusão). Revisão do texto. Defesa da monografia.

Cronograma

Tarefa	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6	Mês 7	Mês 8	Mês 9
Revisão bibliográfica	x	x	x						
Levantamento de requisitos		x	x						
Projeto da arquitetura			x	x	x				
Prototipação				x	x	x	x	x	
Avaliação							x	x	
Escrita da monografia	x	x	x	x	x	x	x	x	x
Revisão e defesa								x	x

Referências Bibliográficas

Alomairy, R., Ltaief, H., Abduljabbar, M. and Keyes, D. (2020). **Abstraction Layer For Standardizing APIs of Task-Based Engines**. IEEE Transactions on Parallel and Distributed Systems, 31(11), 2482-2495. Disponível em: <https://doi.org/10.1109/TPDS.2020.2992923>.

Bernardo, F., Zbyszyński, M., Grierson, M. and Fiebrink, R. (2020). **Designing and Evaluating the Usability of a Machine Learning API for Rapid Prototyping Music Technology**. Frontiers in Artificial Intelligence, 3. Disponível em: <https://doi.org/10.3389/frai.2020.00013>.

Cesari, U., De Pietro, G., Marciano, E., Niri, C., Sannino, G. and Verde, L. (2018). **Voice Disorder Detection via an m-Health System: Design and Results of a Clinical Study to Evaluate Vox4Health**. BioMed Research International, 2018, 8193694. Disponível em: <https://doi.org/10.1155/2018/8193694>.

Dadgar, M., Ennis, C., Mokgosi, K. and Ross, R. (2025). **Artificial intelligence (AI)-driven technologies for managing pediatric speech and language therapy: A scoping review**. Digital Health, 11. Disponível em: <https://doi.org/10.1177/20552076251376533>.

De Rosa, P., Bromberg, Y.-D., Felber, P., Mvondo, D. and Schiavoni, V. (2024). **On the Cost of Model-Serving Frameworks: An Experimental Evaluation**. In: IEEE International Conference on Cloud Engineering (IC2E). Disponível em: <https://doi.org/10.1109/IC2E61754.2024.00032>.

Dovbysh, A. and Aliksieiev, V. (2020). **Development and integration of speech recognition tools into software applications and an approach to improve of speech recognition quality.** In: IEEE 15th International Conference on Advanced Trends in Radioelectronics, Telecommunications and Computer Engineering (TCSET). Disponível em: <https://doi.org/10.1109/TCSET49122.2020.235505>.

Kim, D. H., Jeong, J. W., Kang, D., Ahn, T., Hong, Y., Im, Y., Kim, J., Kim, M. J. and Jang, D.-H. (2025). **Usefulness of Automatic Speech Recognition Assessment of Children With Speech Sound Disorders: Validation Study.** Journal of Medical Internet Research, 27(1), e60520. Disponível em: <https://doi.org/10.2196/60520>.

Li, Y., Pham, D.-S., Ward, R., Hennessey, N. and Tan, T. (2025). **Using AI to Automate Phonetic Transcription and Perform Forced Alignment for Clinical Application in the Assessment of Speech Sound Disorders.** In: 39th AAAI Conference on Artificial Intelligence, GenAI4Health Workshop. Philadelphia, USA. Disponível em: <https://openreview.net/forum?id=WDF1pTFwE>.

Lin, Y.-S., Tseng, S.-C. and Jang, J.-S. R. (2024). **Leveraging Phonemic Transcription and Whisper toward Clinically Significant Indices for Automatic Child Speech Assessment.** In: Interspeech 2024. Disponível em: <https://doi.org/10.21437/Interspeech.2024-1887>.

Mannino, R. G., Arconada Alvarez, S. J., Greenleaf, M., Parsell, M., Mwalija, C. and Lam, W. A. (2023). **Navigating the complexities of mobile medical app development from idea to launch, a guide for clinicians and biomedical researchers.** BMC Medicine, 21, 109. Disponível em: <https://doi.org/10.1186/s12916-023-02833-7>.

Pahl, M.-O. and Loipfinger, M. (2018). **Machine Learning as a Reusable Microservice.** In: IEEE/IFIP Network Operations and Management Symposium (NOMS), p. 1-6. Disponível em: <https://doi.org/10.1109/NOMS.2018.8406165>.

Panchal, D., Baran, I., Musgrove, D. and Lu, D. (2023). **From Models to Microservices: Easily Operationalizing Machine Learning models.** In: IEEE International Conference on Computing and Communication (ICCA). Disponível em: <https://doi.org/10.1109/ICCA59364.2023.10401515>.

Rauf, I., Troubitsyna, E. and Porres, I. (2019). **A systematic mapping study of API usability evaluation methods.** Computer Science Review, 33, 49-68. Disponível em: <https://doi.org/10.1016/j.cosrev.2019.05.001>.

Ribeiro, J. L., Figueredo, M., Araujo, A., Cacho, N. and Lopes, F. (2019). **A Microservice Based Architecture Topology for Machine Learning Deployment.** In: IEEE Symposium on Computers and Communications (ISCC). Disponível em: <https://doi.org/10.1109/ISC246665.2019.9071708>.

Rocha, C. C. (2024). **Creating a Dataset for Automatic Phonetic Transcription in Brazilian Portuguese.** Trabalho de Conclusão de Curso (Graduação em Engenharia Computacional), Universidade Federal de Juiz de Fora, Juiz de Fora.

Roh, S., Jeong, K.-M., Cho, H.-Y. and Huh, E.-N. (2023). **An Efficient Microservices Architecture for MLOps**. In: IEEE 15th International Conference on Ubiquitous and Future Networks (ICUFN). Disponível em: <https://doi.org/10.1109/ICUFN57995.2023.10201181>.

Schröder, S. H., Seitzer, C., Tabriz, N., Töpfer, H., Meyer, J.-M., Fudickar, S., Weyhe, D. and Uslar, V. (2024). **Requirements for the Acceptance of an App for Voice Therapy: A Usability Report Based on the "Oldenburger Logopädie App" (OLA)**. Journal of Voice. Disponível em: <https://doi.org/10.1016/j.jvoice.2024.06.015>.

Singjai, A., Zdun, U., Zimmermann, O. and Pautasso, C. (2022). **Patterns on Deriving APIs and their Endpoints from Domain Models**. In: ACM Symposium on Applied Computing (SAC). Disponível em: <https://doi.org/10.1145/3489449.3489976>.

Vaezipour, A., Campbell, J., Theodoros, D. and Russell, T. (2020). **Mobile Apps for Speech-Language Therapy in Adults With Communication Disorders: Review of Content and Quality**. JMIR mHealth and uHealth, 8(10), e18858. Disponível em: <https://doi.org/10.2196/18858>.

Van Leer, E., Lewis, B. and Porcaro, N. (2021). **Effect of an iOS App on Voice Therapy Adherence and Motivation**. American Journal of Speech-Language Pathology, 30(1), 210-227. Disponível em: https://doi.org/10.1044/2020_AJSLP-19-00213.